Faculdade de Informática e Administração Paulista – FIAP

Tech Challenge – Fase 2

Modelo Preditivo de qualidade de Vinhos com Machine Learning.

Grupo 150

Felipe Macedo da Silva

João Pedro Mezzadri Mottin

Miguel Fernandes Martins de Bastos

Thanael Butewicz

Verônica Machado

Brasil

2026

Introdução e Objetivo

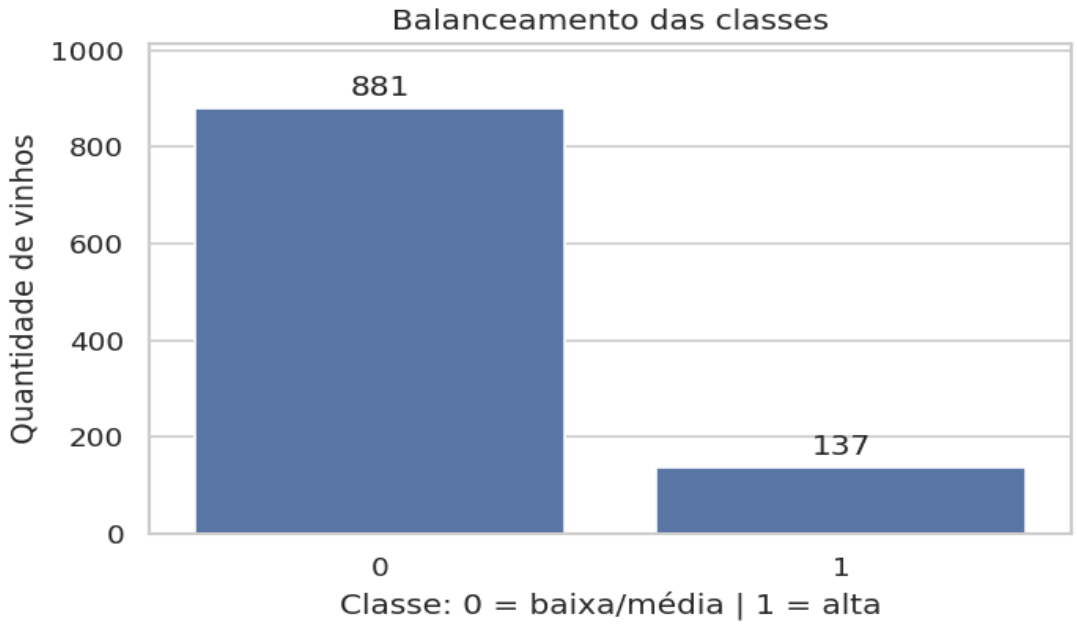
A avaliação tradicional da qualidade de vinhos baseia-se em análises sensoriais realizadas por especialistas, embora valioso, esse processo possuí alta subjetividade e demanda tempo.

Nesse sentido, este projeto visa aplicar técnicas de Machine Learning para confeccionar um modelo preditivo capaz de prever a qualidade do vinho com base nas suas propriedades físico-químicas.

Dados Utilizados.

Para confecção do modelo preditivo, foi utilizado os dados da base pública Wine Quality Dataset (Data/WineQT.csv). A base original contém 1.143 registros. Durante o processo de manipulação e limpeza dos dados, foi realizado a eliminação de 125 dados duplicados, totalizando 1.018 registros únicos

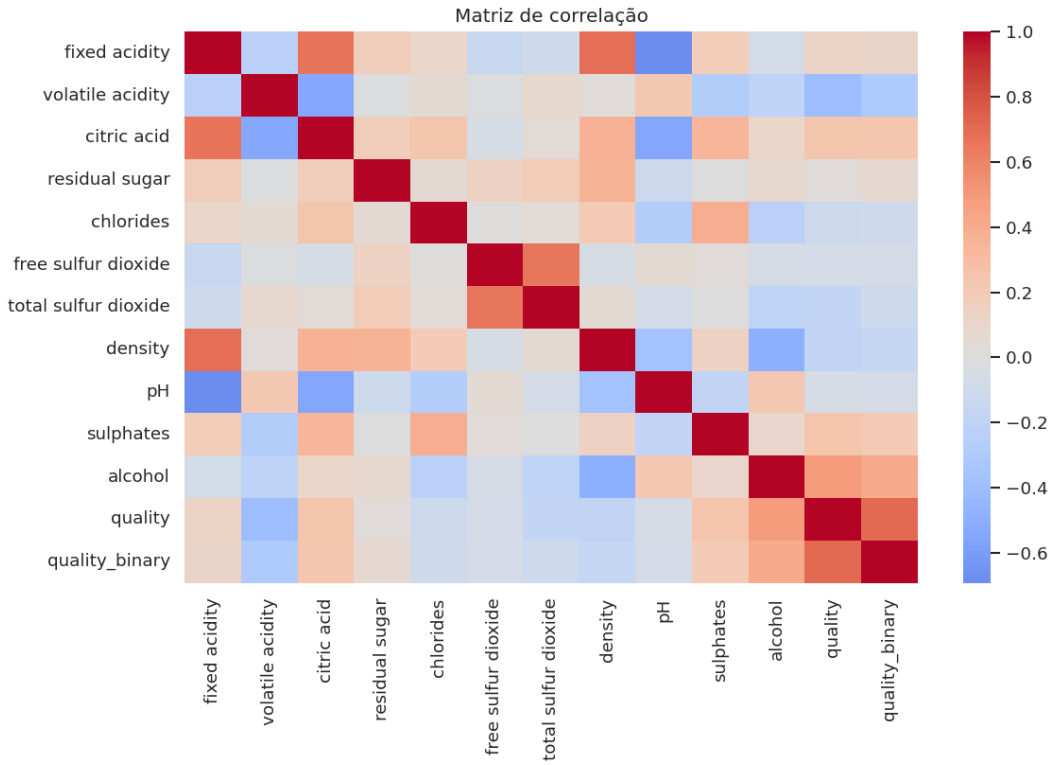
Também foi criada uma coluna de classificação binária para a qualidade, seguindo a regra definida no desafio: notas menores que 7 foram classificadas como baixa/média qualidade, e notas maiores ou iguais a 7 como alta qualidade. A distribuição resultante é apresentada a seguir.



Análise Exploratória

Antes de iniciar o treinamento dos modelos de classificação binária, foi necessário realizar uma análise exploratória dos dados para aprimorar o entendimento de quais variáveis impactam diretamente na qualidade dos vinhos.

Uma das análises é a utilização da matriz de correlação de variáveis.



Através da matriz é possível observar quais variáveis mais se relacionam com a qualidade do vinho:

O **teor alcoólico** tem a correlação positiva mais forte (0,41): vinhos com mais álcool tendem a ter qualidade mais alta.

O **ácido cítrico** (0,24) e os **sulfatos** (0,21) também têm correlação positiva. Ambos contribuem para frescor e conservação do vinho.

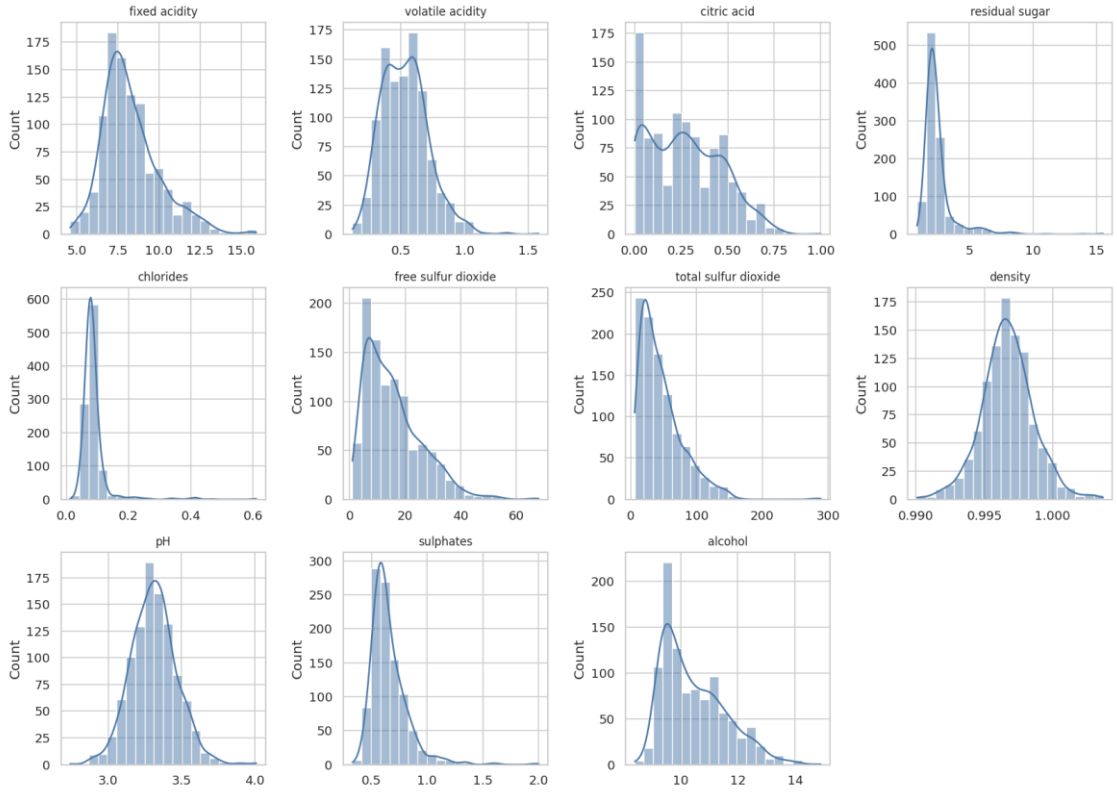
A acidez **volátil** tem a correlação negativa mais forte (-0,30): quanto maior, pior a qualidade, já que está ligada a defeitos no vinho (gosto e cheiro de vinagre).

A **densidade** (-0,17) tem correlação negativa moderada, associada a mais açúcar residual, o que também puxa a qualidade para baixo.

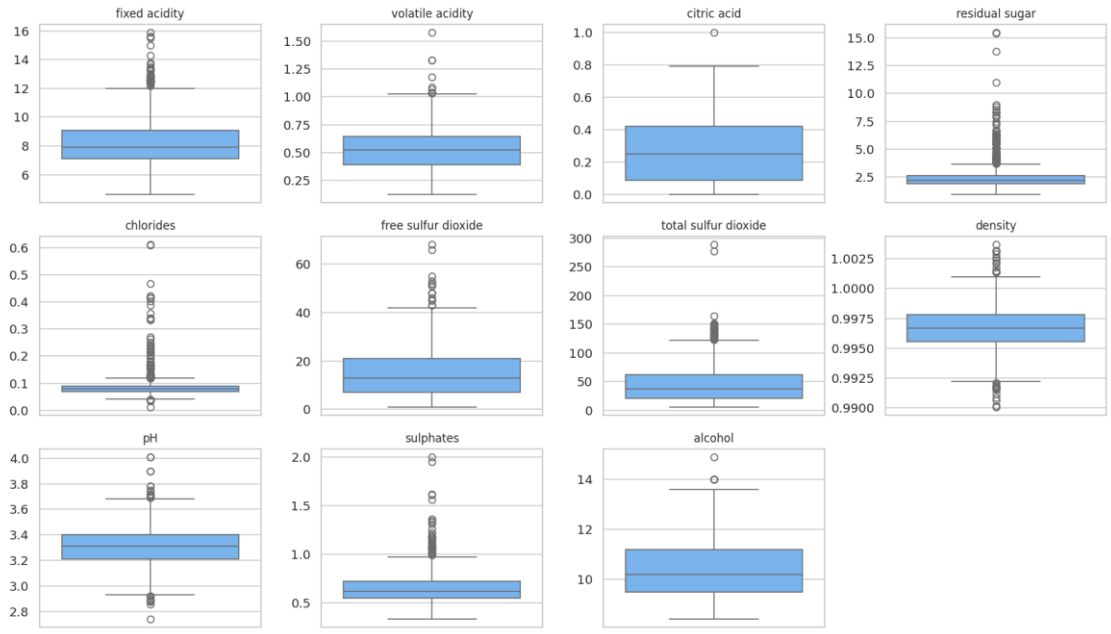
As demais variáveis (açúcar residual, pH, dióxido de enxofre livre) ficaram com correlação próxima de zero, ou seja, pouca relação direta com a qualidade nessa base.

Distribuição das Variáveis e Detecção de Outliers

Além da distribuição da nota de qualidade, também foi analisado como cada variável físico-química se comporta individualmente, o que ajuda a identificar assimetrias e possíveis valores fora do padrão.



A maioria das variáveis apresenta distribuição próxima da normal, com destaque para assimetrias em variáveis como açúcar residual (residual sugar) e cloretos (chlorides), que possuem cauda mais longa à direita. Essa assimetria já é um indício de possíveis valores extremos, investigados a seguir com boxplots.



Utilizando o método do intervalo interquartil (IQR), foi possível identificar que algumas variáveis, como açúcar residual, cloretos e sulfatos, apresentam maior quantidade de valores fora do intervalo esperado. Esses valores não foram removidos da base, pois representam vinhos com composição naturalmente diferente (mais doces, mais ácidos etc.) e não necessariamente erros de medição. Além disso, o Random Forest é naturalmente robusto a outliers, e a Regressão Logística foi treinada com os dados padronizados (*StandardScaler*), o que reduz o impacto de valores extremos no treinamento. Por esses motivos, optou-se por manter todos os registros na base, preservando a variabilidade real dos vinhos analisados.

Preparação dos dados

Para realizar o treinamento dos modelos de classificação que serão utilizados é necessário realizar a separação dos dados de treino e de teste, portanto os dados foram separados da seguinte forma.

75 % dos dados para Treino.
25 % dos dados para Teste.

Antes da separação entre treino e teste, também foi verificada a existência de dados faltantes na base, não sendo encontrado nenhum valor ausente nas colunas utilizadas.

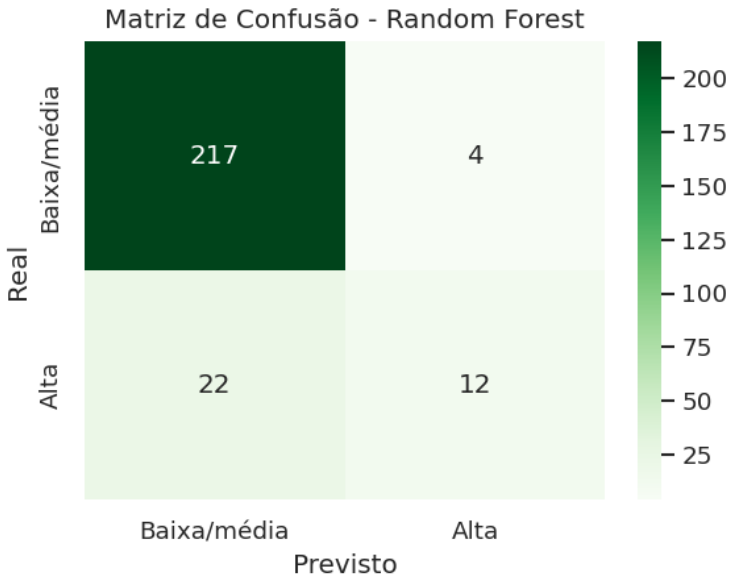
Também foi avaliada a criação de novas variáveis derivadas (feature engineering), como a razão entre dióxido de enxofre livre e total. Optou-se por não incluir novas features no modelo final, pois as 11 variáveis físico-químicas originais já capturam as informações relevantes para a classificação, e a matriz de correlação não indicou lacunas que justificassem a criação de variáveis compostas. Essa decisão prioriza a interpretabilidade do modelo, especialmente da Regressão Logística.

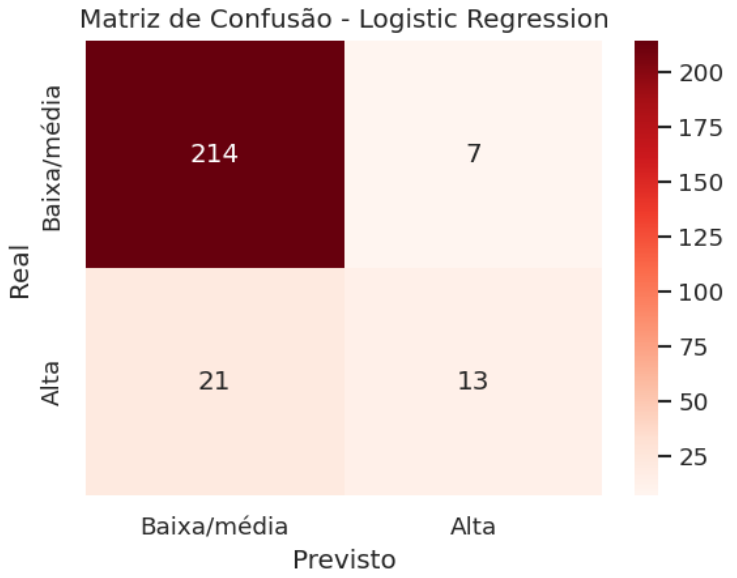
Treinamento dos Modelos.

Para este projeto foi utilizado os modelos de “Logistic Regression” e “Random Forest”, estes modelos foram escolhidos pelas seguintes características.

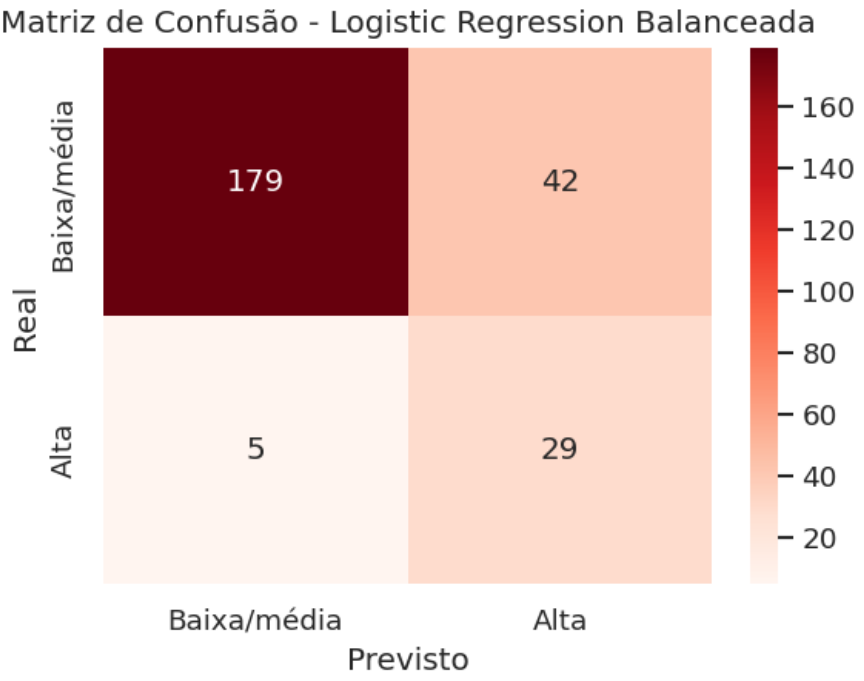
Logistic Regression: Um modelo mais simples e interpretável, facilitando os testes e comparações iniciais.
Random Forest: Modelo baseado em árvore de decisão, sendo amplamente usado para capturar relações mais complexas e analisar a importância das variáveis.

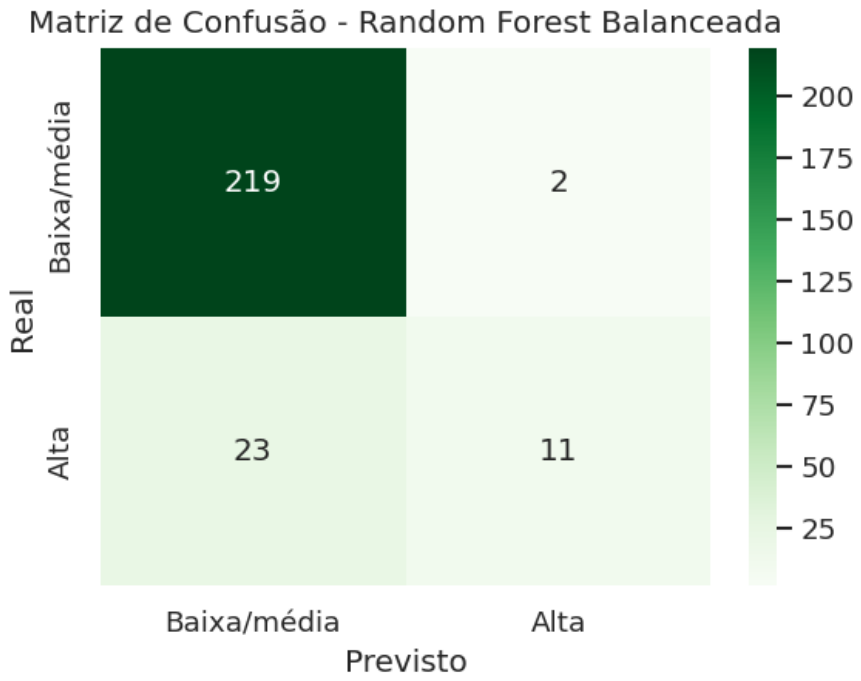
Foi realizado o treinamento dos modelos e comparado os resultados entre os modelos.





Também foi aplicado técnicas de balanceamento para melhorar a previsão dos dados, ficando o seguinte:





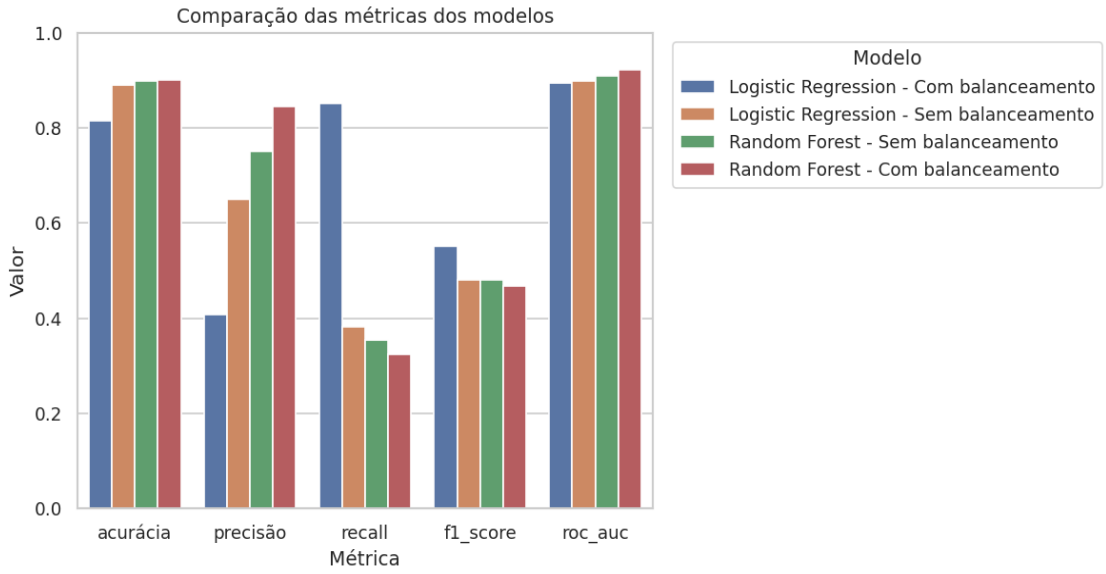
Resultados.

Durante as análises, entendemos que analisar somente a métrica de acurácia dos modelos não seria a forma mais eficiente de avaliar os resultados e escolher qual modelo possui melhor desempenho para ser utilizado em produção.

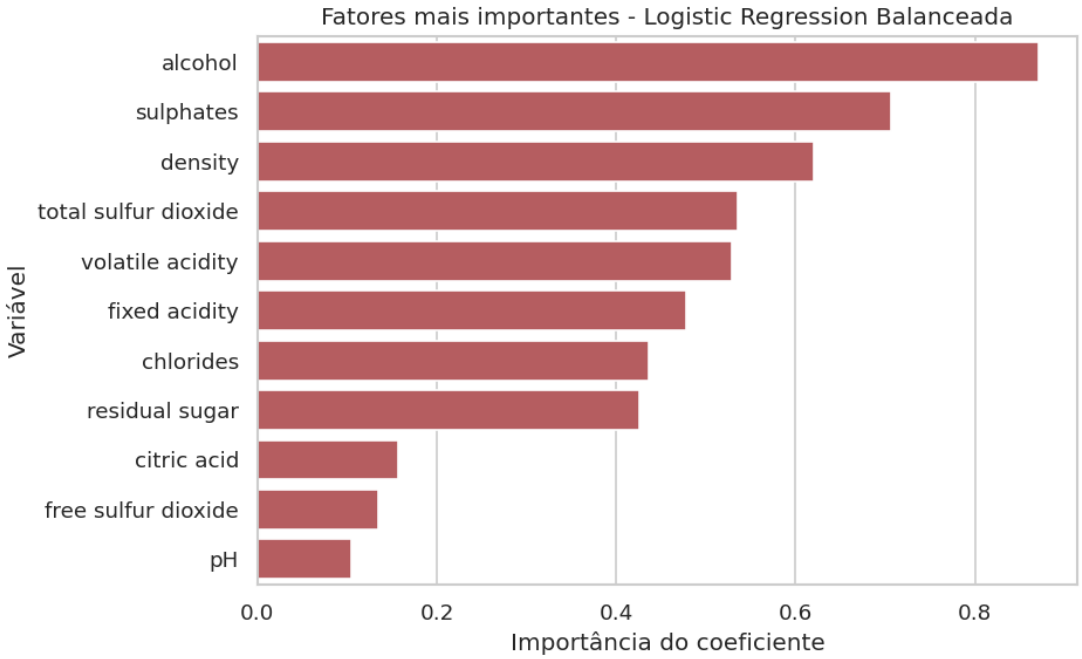
Portanto, para conseguirmos escolher qual modelo obteve a melhor performance foi necessário utilizar novas métricas de avaliação, sendo elas a Precisão, Recall, F1-Score e ROC-AUC.

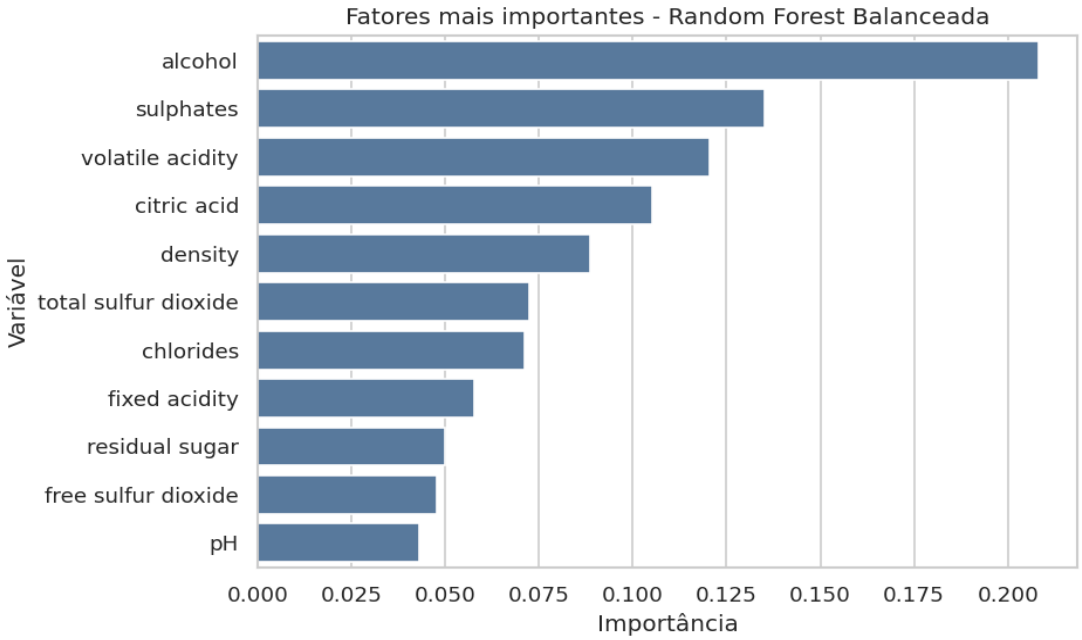
Diante da utilização destas métricas foi possível concluir que o modelo com melhor desempenho baseado nos parâmetros definidos foi o modelo de Random Forest, mantendo uma maior estabilidade ao ser analisado por diferentes métricas.

Na imagem abaixo é possível identificar e comparar os modelos diante de cada métrica avaliada.



A análise de performance dos modelos não se restringiu apenas aos resultados gerados, mas também considerou o grau de influência das variáveis na classificação da qualidade do vinho. Assim, conforme apresentado nas imagens abaixo, mesmo a partir da comparação entre dois modelos distintos de machine learning, é possível identificar os fatores mais relevantes para classificar um vinho no patamar de alta qualidade.





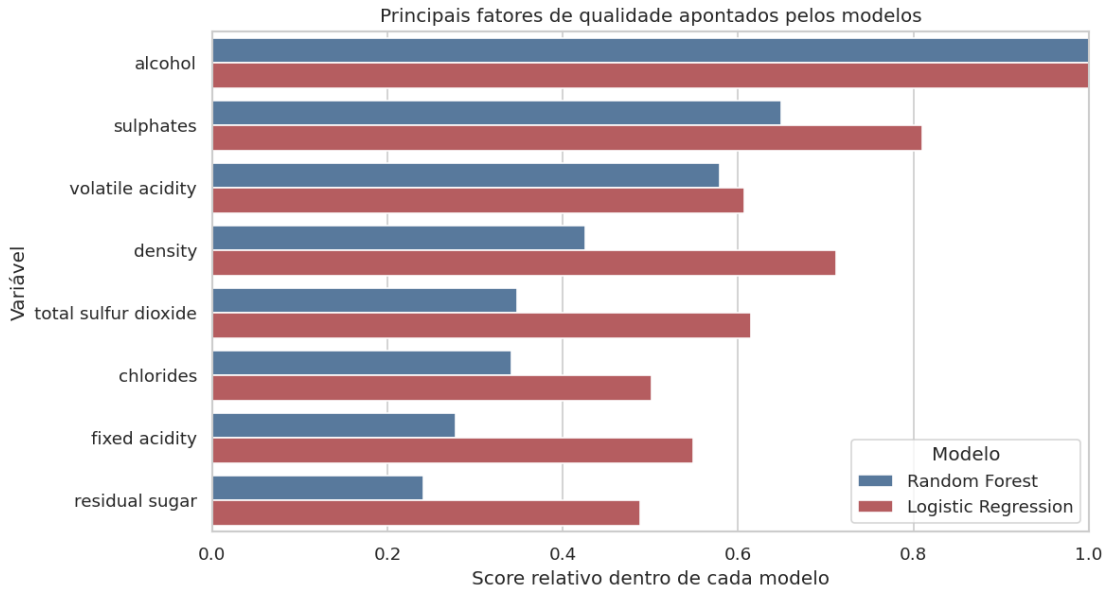
Análise dos Principais Fatores

Ao comparar os dois modelos, fica claro que eles concordam sobre os fatores mais relevantes, mas divergem na forma como distribuem a importância entre eles.

Teor alcoólico: fator mais forte nos dois modelos, sem disputa, o único ponto onde Random Forest e Regressão Logística praticamente empatam no topo.

Sulfatos: segundo fator mais relevante em ambos os modelos, mantendo a posição relativa.

Acidez volátil: terceiro fator mais importante nos dois modelos, com impacto negativo.



(Gráfico: Principais fatores de qualidade apontados pelos modelos)

Implicações para o Processo de Produção

O processo produtivo deve priorizar o monitoramento do teor alcoólico durante a fermentação, buscando o equilíbrio associado a lotes de maior qualidade, além do controle dos níveis de sulfatos, ligados à estabilidade e conservação do vinho.

A acidez volátil também merece atenção especial por ser o ponto mais sensível, já que valores elevados comprometem diretamente aroma e sabor, exigindo ajustes mais rígidos no controle do processo.

Além do acompanhamento desses atributos, o modelo preditivo pode ser usado como triagem por lote, identificando antecipadamente produtos com maior chance de atingir alta qualidade e direcionando recursos técnicos para os casos fora do padrão esperado. Assim, ele funciona como uma camada de apoio à decisão, complementando, nunca substituindo, o conhecimento técnico do enólogo e a avaliação sensorial.

Links

https://github.com/joaomottin/TechChallenge-Fase2/tree/main

https://youtu.be/zjw72T-T930